A Anatomia de um Mecanismo de Busca da Web Hipertextual em Larga Escala

O Artigo Original do Google

Sergey Brin Lawrence Page

Computer Science Department, Stanford University

Computer Networks and ISDN Systems 30 (1998)

Sumário

1. Introdução
2. PageRank: Trazendo Ordem à Web
3. Anchor Text (Texto Âncora)
4. Arquitetura do Sistema
5. Resultados e Desempenho
6. Conclusão

O Desafio da Web (1998)

O Problema

- A Web estava crescendo exponencialmente em informação e usuários.
- Mecanismos de busca existentes (baseados em contagem de palavras-chave) retornavam muitos resultados de baixa qualidade ("junk results").
- Anunciantes tentavam manipular os resultados (spam).
- A tecnologia de busca era vista como uma "arte obscura"comercial, com pouca pesquisa acadêmica pública.

A Solução: Google

- Apresenta o protótipo de um mecanismo de busca em larga escala.
- **Ideia Central:** Fazer uso intenso da estrutura de hipertexto (links) para produzir resultados melhores.
- O nome "Google"é uma variação de "googol"(10^{100}), alinhado ao objetivo de construir um sistema de larguíssima escala.

Funcionalidade Principal 1: PageRank

A Intuição

- O grafo de links da Web é um recurso imenso e subutilizado.
- O PageRank é uma medida **objetiva** da importância de uma página, baseada em citações (links).
- **Ideia-chave:** Um link de uma página A para uma página B é um "voto".
- Mas, ao contrário da contagem simples de backlinks, o PageRank **não conta todos os votos igualmente**.
- Uma página tem PageRank alto se:
  - Muitas páginas apontam para ela;
  - *Ou* poucas páginas **muito importantes** apontam para ela.

PageRank: O Modelo do "Random Surfer"

- O PageRank pode ser entendido como um modelo de comportamento de usuário.
- Imagine um "navegador aleatório"(random surfer):
  - Ele começa em uma página aleatória;
  - Segue os links da página aleatoriamente;
  - Eventualmente, ele "se cansa"e salta para outra página aleatória da Web.
- A probabilidade de o "random surfer"estar em uma determinada página é o seu PageRank.
- O **fator de amortecimento (damping factor)** d (usualmente 0.85) é a probabilidade de o navegador continuar clicando em links, em vez de "se cansar".

PageRank: A Fórmula

Definição

O PageRank de uma página A é dado por:

$$PR(A) = (1 - d) + d \sum_{i=1}^{n} \frac{PR(T_i)}{C(T_i)}$$

Onde:

- A é a página que estamos calculando;
- $T_1, ..., T_n$ são as páginas que apontam para A;
- $PR(T_i)$ é o PageRank da página T_i;
- $C(T_i)$ é o número total de links saindo da página T_i;
- d é o fator de amortecimento.

PageRank: A Fórmula

Definição

O PageRank de uma página A é dado por:

$$PR(A) = (1 - d) + d \sum_{i=1}^{n} \frac{PR(T_i)}{C(T_i)}$$

Onde:

- A é a página que estamos calculando;
- $T_1, ..., T_n$ são as páginas que apontam para A;
- $PR(T_i)$ é o PageRank da página T_i;
- $C(T_i)$ é o número total de links saindo da página T_i;
- d é o fator de amortecimento.

Contexto Matemático

O vetor de PageRanks de todas as páginas corresponde ao **autovetor principal** da matriz de links normalizada da Web.

Funcionalidade Principal 2: Anchor Text

A Ideia

- Mecanismos tradicionais associavam o texto de um link (anchor text) à página que *contém* o link.
- **Abordagem do Google:** Associar o texto âncora à página para a qual o link **aponta**.

Vantagens

1. Âncoras frequentemente fornecem descrições mais precisas da página de destino do que a própria página.
2. Permite indexar documentos que não são baseados em texto (imagens, programas, bancos de dados).
3. Permite retornar páginas que ainda não foram "crawled".

Desafio

Difícil tecnicamente pela grande quantidade de dados. O crawl de 24 milhões de páginas gerou **259 milhões** de âncoras.

Arquitetura do Sistema (Visão Geral)

[Local reservado para a Figura 1 do artigo]

Componentes Principais

- **Crawler:** Vários crawlers distribuídos baixam as páginas.
- **StoreServer/Repository:** Comprime e armazena as páginas baixadas.
- **Indexer:** Lê o repositório, extrai ocorrências de palavras e links.
- **URLresolver:** Converte URLs relativas em absolutas.
- **PageRank:** Calculado sobre o banco de dados de links.
- **Sorter:** Cria o **Inverted Index**.
- **Searcher:** Responde às queries usando o Índice Invertido, o Léxico e o PageRank.

Resultados: Qualidade da Busca

Query Exemplo: "bill clinton"

- **Resultados de Alta Qualidade:** O Google retornou a página principal ‘whitehouse.gov‘.
- Muitos concorrentes não retornavam nenhum resultado relevante.
- **Uso de Anchor Text:** O primeiro resultado não tinha título, foi ranqueado com base no texto âncora.
- O quinto resultado era um e-mail (‘mailto:‘), também encontrado via anchor text.
- **Uso de Proximidade:** Não apareceram resultados para "Bill"ou "Clinton"isolados.

[Local reservado para Figura 2]

Resultados: Desempenho e Escala (1998)

Estatísticas do Protótipo

- **Crawl:** 24 milhões de páginas buscadas.
- **Velocidade de Indexação:** 54 páginas/segundo.
- **Tamanho do Repositório (HTML):** 53.5 GB (comprimido).
- **Índice Invertido:** 37.2 GB.
- **Banco de Dados de Links:** 3.9 GB.

Tempo de Resposta

- Tempo de resposta entre 1 e 10 segundos, dominado por I/O de disco.
- Poucas otimizações foram feitas — foco maior na qualidade do que na velocidade.

Conclusão

- O Google foi projetado como um mecanismo de busca escalável focado primariamente em **alta qualidade** dos resultados.
- A informação hipertextual (links) é fundamental para melhorar a qualidade da busca.
- **Técnicas Principais:**
  - **PageRank:** Avalia objetivamente a qualidade da página.
  - **Anchor Text:** Permite descrições precisas e indexação de conteúdo não textual.
  - **Proximidade:** Aumenta a relevância em queries com múltiplos termos.
- O Google foi também construído como uma **ferramenta de pesquisa** para permitir novos estudos sobre a Web.

Obrigado

Perguntas?