Algoritmo PageRank

MCBM022-23 Introdução aos Processos Estocásticos

UFABC

2025-3

Motivação

- A *Web* pode ser modelada como um **grafo dirigido**:

$$G = (V, E), \quad V = \text{páginas}, \; E = \text{links entre páginas}.$$

- Problema: **como medir a importância de uma página?**

- Ideia do Google:
  "Usar a estrutura de links da Web como um indicador de valor de uma página."

- Cada link é interpretado como um "voto" de uma página a outra.

O Modelo Probabilístico

- Considere o **surfista aleatório**: um usuário que clica em links ao acaso.
- Seja $G = (V, E)$ com $V = \{1, 2, \ldots, n\}$.
- Defina:

$$N^+(a) = \{b \in V : (a, b) \in E\}, \quad d^+(a) = |N^+(a)|$$
$$N^-(a) = \{b \in V : (b, a) \in E\},$$

- O surfista move-se de a para b com probabilidade

$$p_{a,b} = \begin{cases} \frac{1}{d^+(a)}, & \text{se } (a, b) \in E, \\ 0, & \text{caso contrário.} \end{cases}$$

- Assim, $\mathsf{P} = (p_{a,b})$ é a matriz de transição de um passeio aleatório simples em G.

Definição do PageRank

- Cada página a recebe uma pontuação r_a proporcional à soma das pontuações das páginas que apontam para ela

$$r_a = \sum_{b \in N^-(a)} \frac{r_b}{d^+(b)}.$$

- Em forma matricial

Definição do PageRank

- Cada página a recebe uma pontuação r_a proporcional à soma das pontuações das páginas que apontam para ela
$$r_a = \sum_{b \in N^-(a)} \frac{r_b}{d^+(b)}.$$
- Em forma matricial
$$\boldsymbol{r} = \boldsymbol{r}\mathsf{P},$$
isto é, $\boldsymbol{r} = (r_1, r_2, \ldots, r_n)$ é um **vetor invariante** de P.

Problemas do modelo

1. Vértices pendentes (*dangling nodes*)

Páginas sem links de saída: $d^+(a) = 0$.

- Fazem com que P não seja estocástica.

2. Subconjuntos fechados (*rank sinks*)

- Conjuntos de páginas que formam um bloco isolado.
- O surfista fica "preso" e nunca mais sai.

Exemplo de grafo *Web*

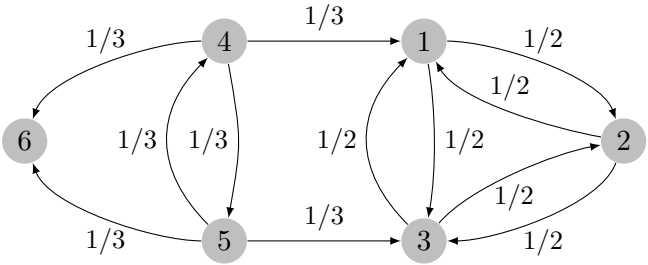

$$P = \begin{pmatrix} 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 1/2 & 0 & 1/2 & 0 & 0 & 0 \\ 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 1/3 & 0 & 0 & 0 & 1/3 & 1/3 \\ 0 & 0 & 1/3 & 1/3 & 0 & 1/3 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

Vértice 6 é pendente $\Rightarrow$ linha nula.

Correção dos vértices pendentes

- Seja $\boldsymbol{u} \in \{0,1\}^n$ o vetor-linha indicador dos vértices pendentes e $\mathbf{1}$ é o vetor-linha de 1's.
- Defina:

$$\mathsf{Q} = \mathsf{P} + \boldsymbol{u}^\intercal \frac{1}{n} \mathbf{1}.$$

- Intuição: se o surfista cai numa página sem links, ele pula para uma página aleatória.
- Agora Q é uma matriz **estocástica**.

Matriz corrigida Q

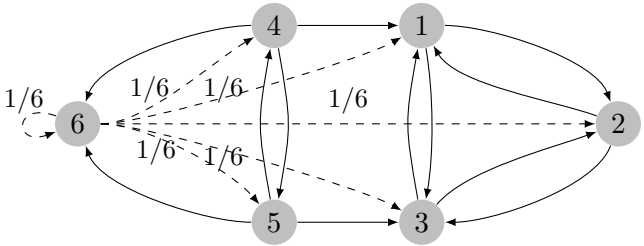

$$Q = \begin{pmatrix} 0 & 1/2 & 1/2 & 0 & 0 & 0 \\ 1/2 & 0 & 1/2 & 0 & 0 & 0 \\ 1/2 & 1/2 & 0 & 0 & 0 & 0 \\ 1/3 & 0 & 0 & 0 & 1/3 & 1/3 \\ 0 & 0 & 1/3 & 1/3 & 0 & 1/3 \\ 1/6 & 1/6 & 1/6 & 1/6 & 1/6 & 1/6 \end{pmatrix}$$

O vértice 6 "pula" para qualquer outro uniformemente.

Tratamento dos subconjuntos fechados

- Ainda pode haver "sorvedouros" de probabilidade.
- Solução: permitir que o surfista reinicie ocasionalmente.
- Com probabilidade $\begin{cases} \alpha, & \text{segue um link;} \\ 1-\alpha, & \text{pula para uma página qualquer.} \end{cases}$

$$\boxed{\mathsf{R} = \alpha \mathsf{Q} + (1-\alpha)\frac{1}{n}\mathbf{1}^\intercal \mathbf{1}}$$

- R é positiva $\Rightarrow$ cadeia ergódica.
- Convergência garantida: $\boldsymbol{\sigma}^{(k)} \xrightarrow[k\to\infty]{} \mathbf{r}$, para qualquer distribuição inicial $\boldsymbol{\sigma}$.

Tratamento dos subconjuntos fechados – Exemplo de grafo *Web*

$$R = \begin{pmatrix} \frac{1-\alpha}{6} & \frac{\alpha}{2}+\frac{1-\alpha}{6} & \frac{\alpha}{2}+\frac{1-\alpha}{6} & \frac{1-\alpha}{6} & \frac{1-\alpha}{6} & \frac{1-\alpha}{6} \\ \frac{\alpha}{2}+\frac{1-\alpha}{6} & \frac{1-\alpha}{6} & \frac{\alpha}{2}+\frac{1-\alpha}{6} & \frac{1-\alpha}{6} & \frac{1-\alpha}{6} & \frac{1-\alpha}{6} \\ \frac{\alpha}{2}+\frac{1-\alpha}{6} & \frac{\alpha}{2}+\frac{1-\alpha}{6} & \frac{1-\alpha}{6} & \frac{1-\alpha}{6} & \frac{1-\alpha}{6} & \frac{1-\alpha}{6} \\ \frac{1-\alpha}{6} & \frac{1-\alpha}{6} & \frac{\alpha}{3}+\frac{1-\alpha}{6} & \frac{1-\alpha}{6} & \frac{\alpha}{3}+\frac{1-\alpha}{6} & \frac{\alpha}{3}+\frac{1-\alpha}{6} \\ \frac{1-\alpha}{6} & \frac{\alpha}{3}+\frac{1-\alpha}{6} & \frac{1-\alpha}{6} & \frac{\alpha}{3}+\frac{1-\alpha}{6} & \frac{1-\alpha}{6} & \frac{\alpha}{3}+\frac{1-\alpha}{6} \\ \frac{\alpha}{6}+\frac{1-\alpha}{6} & \frac{\alpha}{6}+\frac{1-\alpha}{6} & \frac{\alpha}{6}+\frac{1-\alpha}{6} & \frac{\alpha}{6}+\frac{1-\alpha}{6} & \frac{\alpha}{6}+\frac{1-\alpha}{6} & \frac{\alpha}{6}+\frac{1-\alpha}{6} \end{pmatrix}$$

Tratamento dos subconjuntos fechados – Exemplo de grafo *Web*

$$R = \begin{pmatrix} 0.025 & 0.45 & 0.45 & 0.025 & 0.025 & 0.025 \\ 0.45 & 0.025 & 0.45 & 0.025 & 0.025 & 0.025 \\ 0.45 & 0.45 & 0.025 & 0.025 & 0.025 & 0.025 \\ 0.025 & 0.025 & 0.3083 & 0.025 & 0.3083 & 0.3083 \\ 0.025 & 0.3083 & 0.025 & 0.3083 & 0.025 & 0.3083 \\ 0.1667 & 0.1667 & 0.1667 & 0.1667 & 0.1667 & 0.1667 \end{pmatrix}$$

$$\alpha = 0{,}85$$

Resposta aqui

Cálculo iterativo do PageRank

- Método das potências:

$$\boldsymbol{\sigma}^{(k+1)} = \boldsymbol{\sigma}^{(k)}\mathsf{R}.$$

- Convergência com taxa $|\lambda_2/\lambda_1|$.
- Nesse caso, $\lambda_1 = 1$ e $|\lambda_2| < \alpha$.
- Valor usado pelo Google: $\alpha = 0{,}85$.

$$\|\boldsymbol{\sigma}^{(t+1)} - \boldsymbol{\sigma}^{(t)}\| < \varepsilon$$

Critério de parada: $\varepsilon \in [10^{-2}, 10^{-7}]$, 50–100 iterações.

Versão computacional

- A matriz P é **esparsa**.
- É suficiente armazenar: a estrutura de P, o vetor $\boldsymbol{u}$
- A iteração prática:

$$\boldsymbol{\sigma}^{(t)} = \alpha \boldsymbol{\sigma}^{(t-1)} \mathsf{P} + \alpha (\boldsymbol{\sigma}^{(t-1)} \mathbf{u}^{\intercal}) \frac{1}{n} \mathbf{1} + (1-\alpha) \frac{1}{n} \mathbf{1}$$

onde $\boldsymbol{\sigma}^{(t-1)} \mathbf{u}^{\intercal}$ é um escalar (massa atual em vértices pendentes) — assim evita-se multiplicar matrizes densas.

Referências

- Page, L.; Brin, S.; Motwani, R.; Winograd, T. *The PageRank Citation Ranking: Bringing Order to the Web.* Stanford (1998)
- Haveliwala, T. H. *Second eigenvalue of the Google matrix.* Stanford (2003)